

**Sistema de evaluación de riesgos de privacidad y fuga de datos en el uso de modelos de
lenguaje de gran escala (LLM) en instituciones de educación superior en Medellín,
Colombia**

Jesús Antonio Acevedo Montoya

Daniel Felipe Villa Duarte

Juan Pablo Londoño Corrales

202016907 - Proyecto de grado

Tutor: Daniel Andrés Guzmán Arevalo

Programa de Ingeniería de Sistemas

Escuela de Ciencias Básicas Tecnología e Ingeniería

Universidad Nacional Abierta y a Distancia

27 de julio de 2026

Lista de contenido

Abstract	1
Resumen.....	2
Introducción	3
Líneas y grupos de interés investigativo	4
Planteamiento del problema.....	5
Pregunta de investigación	6
Árbol causa – efecto del problema.....	6
Causas principales.....	8
Efectos.....	8
Justificación	9
Objetivos	10
Objetivo general.....	10
Objetivos específicos	10
Delimitación del proyecto	11
Delimitación espacial.....	11
Delimitación temporal	12
Delimitación temática	12
Delimitación poblacional	12
Delimitación tecnológica	12
Antecedentes	13
Antecedentes internacionales.....	13
Antecedentes nacionales	14
Antecedentes regionales.....	14
Marco referencial	15
Marco teórico	15
Marco conceptual.....	17
Marco legal	19
Marco tecnológico	20
Metodología	22
Metodología científica	22

Población y muestra.....	24
Instrumentos de medición y recolección de datos	25
Análisis y diagnóstico del proceso investigativo	26
Metodología de desarrollo – scrum.....	26
Roles scrum.....	26
Product backlog	27
Planificación de sprints	29
Ceremonias scrum.....	30
Criterios de aceptación global.....	32
Diseño de la solución	32
Arquitectura del sistema	32
Flujo del proceso de evaluación de riesgos	34
Casos de uso del sistema.....	35
Modelo de datos conceptual	38
Resultados del desarrollo del prototipo.....	40
Resultados o productos esperados	42
Cronograma de actividades.....	43
Recursos necesarios para la implementación.....	45
Conclusiones	48
Referencias.....	49

Lista de tablas

Tabla 1. Relación de intereses investigativos, líneas y grupos de investigación.....	4
Tabla 2. Marco legal	19
Tabla 3. Arquitectura tecnológica del proyecto	21
Tabla 4. Product Backlog – Historias de usuario priorizadas	27
Tabla 5. Planificación de Sprints – Objetivos e incrementos	29
Tabla 6. Requerimientos funcionales.....	31
Tabla 7. Requerimientos no funcionales.....	32
Tabla 8. Arquitectura del sistema	33
Tabla 9. Casos de uso del sistema.....	35
Tabla 10. Modelo de datos conceptual	39
Tabla 11. Resultados y productos esperados del proyecto	42
Tabla 12. Cronograma de actividades.....	44
Tabla 13. Recursos necesarios	45

Lista de ilustraciones

Ilustración 1. Árbol de problema	7
Ilustración 2. Vista general del prototipo – Página de inicio	41
Ilustración 3. Vista del módulo de prototipos y demostraciones interactivas.....	41

Abstract

The massive adoption of Large Language Models (LLM) in higher education institutions (HEI) in Medellín has created a critical data governance gap: these tools are being integrated into academic and administrative processes without institutional privacy risk assessment frameworks aligned with Colombian Law 1581 of 2012. This applied project aims to design a privacy and data leakage risk evaluation framework, supported by privacy auditing methodologies and severity matrix parameterization, to ensure the safe and ethical adoption of LLMs in Colombian HEIs. The research employs a mixed-methods approach with a sequential explanatory design: the quantitative phase will measure data exposure levels through structured surveys applied in at least three institutions, while the qualitative phase will deepen governance gap analysis through semi-structured interviews with IT directors and data protection officers. Technological development will follow the Scrum agile methodology, organized into four sprints, and will culminate in a functional prototype at TRL5 maturity level deployed in a testing environment. Expected outcomes include an expert-validated framework, a quantified privacy risk matrix for LLMs in educational contexts, and best-practice guidelines aligned with the NIST AI RMF 1.0 and CONPES 4144.

Keywords: large language models, data privacy, privacy auditing, higher education institutions, artificial intelligence governance.

Resumen

La adopción masiva de Modelos de Lenguaje de Gran Escala (LLM) en instituciones de educación superior (IES) de Medellín ha generado una brecha crítica de gobernanza de datos: estas herramientas se integran en procesos académicos y administrativos sin que existan marcos institucionales de evaluación de riesgos de privacidad alineados con la Ley 1581 de 2012. El presente proyecto aplicado tiene como objetivo diseñar un framework de evaluación de riesgos de privacidad y fuga de datos, sustentado en metodologías de auditoría de privacidad (privacy auditing) y en la parametrización de matrices de severidad, que garantice la adopción segura y ética de los LLM en las IES colombianas. La investigación adopta un enfoque mixto de tipo secuencial explicativo: la fase cuantitativa medirá el nivel de exposición de datos mediante encuestas estructuradas aplicadas en al menos tres IES, mientras que la fase cualitativa profundizará en las brechas de gobernanza a través de entrevistas semiestructuradas a directivos TIC y oficiales de protección de datos. El desarrollo tecnológico seguirá la metodología ágil Scrum, organizado en cuatro sprints, y culminará en un prototipo funcional con nivel de madurez tecnológica TRL5 desplegado en entorno de pruebas. Los resultados esperados incluyen un framework validado por expertos, una matriz cuantificada de riesgos de privacidad para LLM en contextos educativos y guías de buenas prácticas alineadas con el NIST AI RMF 1.0 y el CONPES 4144.

Palabras clave: modelos de lenguaje de gran escala, privacidad de datos, auditoría de privacidad, instituciones de educación superior, gobernanza de inteligencia artificial.

Introducción

A nivel global, la adopción de Modelos de Lenguaje de Gran Escala (LLM), como ChatGPT, Gemini y Claude, ha transformado de manera acelerada los ecosistemas educativos universitarios. En el contexto colombiano, y particularmente en Medellín, este fenómeno ha cobrado una relevancia especial: la ciudad concentra más de 25 instituciones de educación superior (IES) activas, muchas de las cuales se encuentran en plena transición hacia modelos de gestión académica y administrativa mediados por inteligencia artificial generativa (Hosseini-Mohand et al., 2025). Datos recientes del Ministerio de Educación Nacional evidencian que el 58% del estudiantado colombiano no se siente institucionalmente preparado para interactuar con entornos de IA, mientras que únicamente el 22% del profesorado posee competencias digitales avanzadas para su uso responsable (Ministerio de Educación Nacional, 2025).

En términos de ciberseguridad, los LLM plantean vectores de amenaza específicos que la ingeniería de sistemas está llamada a diagnosticar y contener. La organización OWASP (2025) identificó que las vulnerabilidades más críticas en el despliegue de LLMs incluyen la inyección de prompts, el manejo inadecuado de salidas y la divulgación accidental de información confidencial a través de la memorización de datos de entrenamiento. Estas características técnicas adquieren una gravedad jurídica particular en Colombia, donde la Ley 1581 de 2012 y el Decreto 1377 de 2013 imponen obligaciones explícitas de protección de datos personales sobre cualquier organización que los trate, incluyendo a las IES.

Este documento presenta el proyecto aplicado orientado a diseñar e implementar un framework de diagnóstico de riesgos de privacidad en el uso de LLMs dentro de las IES de Medellín. El texto se organiza en los siguientes apartados: líneas de investigación, planteamiento del problema, árbol causal, justificación, objetivos, delimitación, antecedentes, marco referencial, metodología, desarrollo Scrum, cronograma, recursos, resultados y conclusiones.

Líneas y grupos de interés investigativo

Tabla 1. Relación de intereses investigativos, líneas y grupos de investigación.

<i>Intereses en ingeniería e investigación</i>	<i>Línea de investigación y áreas temáticas</i>	<i>Grupo de investigación</i>
Evaluación de riesgos de ciberseguridad, auditoría de privacidad (<i>privacy auditing</i>) y modelamiento de vectores de fuga de datos en sistemas basados en Inteligencia Artificial Generativa.	Seguridad Informática / Infraestructuras digitales y sistemas inteligentes (ECBTI-UNAD).	Semillero de Investigación SIIATE – CEAD Medellín, Zona Occidente (ZOCC).

Planteamiento del problema

La adopción masiva de modelos de lenguaje de gran escala (LLM) en IES ha abierto una brecha de gobernanza de datos sin precedentes. Según el AI Risk Management Framework del NIST, los sistemas de inteligencia artificial procesan datos en flujos que pueden volverse opacos para los usuarios, incrementando la probabilidad de exposición no autorizada de información sensible (Tabassi, 2023). OWASP identificó en su Top 10 para LLMs 2025 que la inyección de prompts, la divulgación de información confidencial y el envenenamiento de datos constituyen las vulnerabilidades más críticas en contextos de despliegue real (OWASP Foundation, 2025). A nivel internacional, múltiples investigaciones documentan que las instituciones educativas son objetivos prioritarios de brechas de seguridad porque administran grandes volúmenes de datos personales sin protocolos de privacidad robustos (Wada et al., 2025).


En Colombia, la Ley 1581 de 2012 y el Decreto Reglamentario 1377 de 2013 imponen obligaciones específicas sobre el tratamiento de datos de menores y personas en condición de vulnerabilidad. El Ministerio de Educación Nacional reconoció en 2025 que persisten brechas significativas: solo el 22% del profesorado utiliza herramientas de IA con competencias avanzadas y el 58% del estudiantado no se siente preparado para un entorno mediado por inteligencia artificial, evidenciando una adopción que supera la capacidad institucional de gestión de riesgos (Hosseini-Mohand et al., 2025). El proyecto de ley radicado ante el Congreso colombiano clasifica los sistemas de IA en educación como de alto riesgo, reforzando la urgencia de intervenir desde la investigación aplicada (Congreso de la República de Colombia, 2025).

Pregunta de investigación

¿Cuáles son los riesgos de privacidad y fuga de datos asociados al uso de modelos de lenguaje de gran escala (LLM) en instituciones de educación superior de Medellín, Colombia, y qué mecanismos de evaluación y mitigación resultan adecuados para el contexto normativo colombiano?

Árbol causa – efecto del problema

Ilustración 1. Árbol de problema



Problema central: Ausencia de gobernanza de datos y evaluación de riesgos de privacidad en la integración de LLMs en los procesos administrativos de las IES de Medellín.

Causas principales

- C1 – Desconocimiento institucional sobre riesgos de privacidad en LLMs: falta de capacitación, ausencia de roles DPO, brecha de competencias digitales (solo el 22% del profesorado utiliza IA – MEN, 2025).
- C2 – Ausencia de marcos institucionales de gobernanza de IA: inexistencia de políticas de uso, contratos con proveedores sin cláusulas de tratamiento de datos, carencia de comités de ética.
- C3 – Adopción tecnológica acelerada sin evaluación previa de riesgos: presión competitiva, bajo presupuesto para ciberseguridad, dependencia de proveedores internacionales con políticas de retención opacas.
- C4 – Vulnerabilidades técnicas estructurales de los LLMs (subcausas): memorización de datos de entrenamiento (Carlini et al., 2021), inyección de prompts y manejo inadecuado de salidas (OWASP, 2025).

Efectos

- E1 – Exposición no autorizada de datos personales de estudiantes, docentes y menores de edad.

- E2 – Sanciones legales de la SIC bajo la Ley 1581 de 2012 (multas hasta 2.000 SMMLV).
- E3 – Pérdida de confianza institucional y daño reputacional para las IES.
- E4 – Afectación financiera por litigios, procesos de cumplimiento forzado y costos de remediación.
- E5 – Deterioro de la calidad de decisiones académicas basadas en datos comprometidos.

Justificación

La integración de LLMs en procesos administrativos educativos plantea riesgos concretos sobre datos personales de estudiantes, docentes y personal administrativo, sujetos a protección bajo la Ley 1581 de 2012. La adopción de estas tecnologías sin evaluación previa de riesgos puede derivar en brechas de seguridad con consecuencias legales, económicas y reputacionales para las IES (Tabassi, 2023). Investigaciones recientes señalan que los LLMs presentan vulnerabilidades intrínsecas — como la memorización de datos de entrenamiento y la generación de respuestas con información confidencial— que representan riesgos sistémicos cuando se despliegan en entornos con datos sensibles (OWASP Foundation, 2025).

Este proyecto se articula con el ODS 4 (Educación de calidad) en su dimensión de entornos de aprendizaje seguros e inclusivos, y con el ODS 16 (Paz, justicia e instituciones sólidas). A nivel nacional, el CONPES 4144 y la Hoja de Ruta de IA identifican a las IES como actores clave para el desarrollo de una IA ética y sostenible

(Departamento Nacional de Planeación, 2023). Los resultados de esta investigación contribuirán a llenar el vacío teórico existente sobre riesgos de privacidad de LLMs en el contexto educativo latinoamericano. Los beneficiarios directos incluyen las oficinas TIC, los responsables del tratamiento de datos y los oficiales de protección de datos (DPOs) de las IES de Medellín.

Objetivos

Objetivo general

Diseñar un framework de evaluación de riesgos de privacidad y fuga de datos mediante metodologías de auditoría de privacidad (privacy auditing) y la parametrización de matrices de severidad para garantizar la adopción segura, ética y el cumplimiento del marco normativo de protección de datos personales en el uso de modelos de lenguaje de gran escala (LLM) dentro de las instituciones de educación superior de Medellín, Colombia.

Objetivos específicos

- OE1 – Identificar mediante técnicas de revisión bibliográfica y documental los escenarios críticos de uso de herramientas LLM y la taxonomía de datos involucrados para establecer la línea base de exposición normativa en las IES de Medellín. [Bloom N1 – Recordar]

- OE2 – Caracterizar a través del mapeo de vulnerabilidades del estándar OWASP

Top 10 los mecanismos técnicos de fuga de datos en modelos generativos para determinar su correspondencia con las categorías de datos sensibles de la legislación colombiana.

[Bloom N2 – Comprender]

- OE3 – Analizar mediante encuestas estructuradas y entrevistas semiestructuradas

las brechas en las políticas institucionales de privacidad frente a las directrices del

CONPES 4144 e ISO/IEC 27701 en al menos tres IES de Medellín. [Bloom N4 –

Analizar]

- OE4 – Evaluar mediante pruebas experimentales con datos sintéticos el nivel de

exposición de información para cuantificar, a través de métricas estándar, la probabilidad

e impacto de los riesgos de privacidad en contextos educativos. [Bloom N5 – Evaluar]

- OE5 – Proponer el framework definitivo con lineamientos y guías de buenas

prácticas para orientar la mitigación operativa y el cumplimiento normativo en las IES de

Medellín. [Bloom N6 – Crear].

Delimitación del proyecto

Delimitación espacial

El proyecto se desarrolló en instituciones de educación superior públicas y privadas ubicadas en Medellín y el área metropolitana del Valle de Aburrá, Antioquia. Se seleccionaron al menos tres IES con uso documentado de herramientas LLM en procesos

administrativos o académicos durante el año 2026. No se incluyen instituciones de nivel técnico o tecnológico.

Delimitación temporal

El proyecto se ejecutó durante el segundo semestre de 2026, con una duración máxima de seis (6) meses, organizados en cuatro sprints de aproximadamente seis semanas cada uno. La recolección de datos primarios se realizó en el Sprint 2 (meses 2-3).

Delimitación temática

El estudio se inscribe en las áreas de seguridad informática, gobernanza de datos y evaluación de riesgos aplicada a sistemas de inteligencia artificial generativa. No aborda el diseño o modificación de modelos LLM internamente, ni la evaluación de riesgos distintos a los de privacidad y fuga de datos.

Delimitación poblacional

La población objetivo son los actores institucionales responsables del tratamiento de datos en las IES seleccionadas: directivos de áreas TIC, oficiales de protección de datos (DPOs), docentes usuarios regulares de LLMs y estudiantes de posgrado. Se excluyen menores de 18 años como sujetos de estudio directo.

Delimitación tecnológica

El prototipo funcional se desarrolló con tecnologías de código abierto: Next.js 16 + TypeScript (frontend), GitHub para control de versiones, y fue desplegado en Vercel. Las pruebas de auditoría de privacidad se realizaron con Microsoft Presidio y Giskard AI sobre datos sintéticos, garantizando el cumplimiento de la Ley 1581 de 2012.

Antecedentes

Antecedentes internacionales

Carlini et al. (2021). Extracting Training Data from Large Language Models.

Este estudio demostró experimentalmente que los LLMs pueden memorizar y reproducir fragmentos de sus datos de entrenamiento, incluyendo información personal identificable. Los investigadores extrajeron con éxito direcciones de correo electrónico, números de teléfono y fragmentos de texto privados de modelos tipo GPT-2. El hallazgo fundamenta técnicamente la vulnerabilidad de memorización que se incluye en la taxonomía de riesgos del framework.

OWASP Foundation (2025). OWASP Top 10 for Large Language Model Applications.

Este estándar identifica las diez vulnerabilidades más críticas en aplicaciones basadas en LLMs: inyección de prompts (LLM01), divulgación de información confidencial (LLM06) y manejo inadecuado de salidas (LLM05). El proyecto adoptó esta taxonomía como eje estructural para el diseño de los instrumentos de auditoría.

Tabassi, E. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST.

El NIST AI RMF 1.0 proporciona una estructura de cuatro funciones (Gobernar, Mapear, Medir, Gestionar) para la gestión de riesgos en sistemas de IA. El proyecto adoptó este framework como base metodológica para construir la matriz de evaluación de riesgos específica para LLMs en IES colombianas.

Antecedentes nacionales

Ministerio de Educación Nacional (2025). Informe sobre competencias digitales y adopción de IA en educación superior colombiana.

El informe registra que solo el 22% del profesorado posee competencias digitales avanzadas para el uso de IA y que el 58% del estudiantado no se siente preparado para entornos mediados por inteligencia artificial. Estos datos constituyen la evidencia cuantitativa de base que justifica la pertinencia regional del proyecto (Hosseini-Mohand et al., 2025).

Departamento Nacional de Planeación (2023). CONPES 4144 – Política Nacional de Inteligencia Artificial.

El CONPES 4144 establece los lineamientos de política pública para el desarrollo, adopción y gobernanza de la IA en Colombia, identificando a las IES como actores estratégicos. El proyecto se alinea directamente con las metas de gobernanza responsable de IA.

Antecedentes regionales

Mora Torres, A. (2026). Brechas en gobernanza digital en IES de Medellín. Repositorio UNAD.

Este estudio regional documentó que en las IES del Valle de Aburrá la adopción de herramientas de IA generativa ocurre de forma no planificada en materia de privacidad, sin políticas institucionales de uso responsable. El vacío investigativo identificado coincide directamente con el objeto de estudio de este proyecto.

Vasquez Blanco, C. (2026). Adopción de LLMs en educación superior latinoamericana. Repositorio UNAD.

La investigación analizó patrones de adopción de herramientas LLM en universidades de la región, concluyendo que la falta de marcos de gobernanza representa el principal factor de riesgo de privacidad, reforzando la necesidad del framework propuesto.

Marco referencial

Marco teórico

La fundamentación teórica del proyecto integra tres cuerpos de conocimiento: la gestión de riesgos de sistemas de IA, la auditoría de privacidad en entornos digitales y la gobernanza de datos en organizaciones.

Gestión de riesgos de IA (NIST AI RMF 1.0).

El AI Risk Management Framework del NIST (Tabassi, 2023) proporciona un modelo de cuatro funciones para la gestión responsable de sistemas de IA: Gobernar (establecer cultura y responsabilidades), Mapear (identificar riesgos contextuales), Medir (analizar, priorizar y cuantificar riesgos) y Gestionar (responder y monitorear riesgos). Este modelo es adoptado como eje estructural del framework a desarrollar, adaptando cada función al contexto específico de las IES colombianas y sus obligaciones bajo la Ley 1581 de 2012.

Vulnerabilidades en LLMs (OWASP Top 10).

El estándar OWASP Top 10 para LLMs (OWASP Foundation, 2025) categoriza las diez vulnerabilidades más críticas en aplicaciones basadas en modelos de lenguaje. Para este proyecto, los vectores de mayor relevancia son: LLM01 (Inyección de prompts), LLM02 (Manejo inadecuado de salidas), LLM06 (Divulgación de información confidencial) y LLM08 (Agencia excesiva). Estas categorías estructurarán la taxonomía de riesgos de privacidad que se construirá en el OE2.

Memorización en LLMs.

Carlini et al. (2021) demostraron que los LLMs pueden memorizar y reproducir información personal de sus datos de entrenamiento. Esta vulnerabilidad de memorización implica que los usuarios que interactúan con plataformas LLM de terceros pueden estar contribuyendo involuntariamente al futuro entrenamiento de modelos con datos identificables, sin que exista control institucional sobre dicha transferencia.

Ciberseguridad en sistemas con componentes de IA.

Camacho et al. (2024) proponen un modelo de evaluación de ciberseguridad específicamente diseñado para sistemas que integran componentes de IA, destacando la necesidad de adaptar los marcos tradicionales de gestión de riesgos (ISO/IEC 27001) para contemplar los vectores de ataque únicos de los modelos generativos, como la adversarial robustness y el data poisoning.

Gobernanza de IA en IES.

Delgado Salas et al. (2025) analizaron modelos de gobernanza de IA implementados en universidades iberoamericanas, identificando que las instituciones con mayor madurez digital habían adoptado políticas de IA ética que incorporaban principios

de privacidad desde el diseño (privacy by design) como condición previa al despliegue de cualquier herramienta de IA. Sus hallazgos orientarán la fase de propuesta del framework (OE5).

Marco conceptual

Modelos de Lenguaje de Gran Escala (LLM).

Los LLM son sistemas de inteligencia artificial entrenados con grandes corpus de datos textuales mediante técnicas de deep learning, específicamente arquitecturas basadas en transformadores, que les permiten comprender y generar lenguaje natural con alta fluidez y coherencia (Brown et al., 2020). En el contexto educativo, los LLM se despliegan como asistentes conversacionales, motores de resumen, generadores de retroalimentación automatizada y herramientas de soporte administrativo, procesando en su interacción datos que pueden incluir información personal identificable de los usuarios.

Fuga de datos y memorización en LLMs.

La fuga de datos en el contexto de los LLMs se refiere a la divulgación no intencional de información confidencial a través de las respuestas generadas por el modelo. Este fenómeno puede ocurrir por dos mecanismos principales: la memorización de datos de entrenamiento, mediante la cual el modelo reproduce verbatim fragmentos de información privada presentes en el corpus de entrenamiento (Carlini et al., 2021), y la inferencia a partir de contexto, donde el modelo extrapola información confidencial a partir de patrones estadísticos aprendidos. Ambos mecanismos son especialmente

riesgosos en entornos educativos donde los prompts frecuentemente contienen datos identificables.

Auditoría de privacidad (Privacy Auditing).

La auditoría de privacidad es el proceso sistemático de evaluación de las medidas técnicas y organizacionales implementadas por una entidad para proteger los datos personales bajo su custodia, verificando su conformidad con los requisitos legales aplicables y con los estándares internacionales de protección de datos (ISO/IEC 27701). En el contexto de los sistemas de IA, el privacy auditing incorpora pruebas específicas de extracción de información memorizada, análisis de flujos de datos hacia proveedores externos y evaluación de las cláusulas contractuales de tratamiento de datos.

Gobernanza de datos en IA.

La gobernanza de datos en el contexto de sistemas de inteligencia artificial abarca el conjunto de políticas, procedimientos, roles y tecnologías que una organización implementa para garantizar que los datos utilizados o generados por sistemas de IA sean manejados de forma íntegra, segura, conforme a la regulación y alineada con los valores éticos institucionales (Delgado Salas et al., 2025). Los elementos clave de un modelo de gobernanza de datos para IA incluyen: clasificación de datos, definición de responsabilidades (data ownership), protocolos de consentimiento informado, mecanismos de trazabilidad y procedimientos de respuesta a incidentes.

Framework de evaluación de riesgos.

En ingeniería de sistemas, un framework de evaluación de riesgos es un conjunto estructurado de procedimientos, criterios y herramientas que permite identificar, analizar,

priorizar y proponer respuestas ante amenazas que pueden afectar los activos de información de una organización (Tabassi, 2023). Para el contexto de LLMs en IES, el framework propuesto en este proyecto integrará matrices de severidad basadas en probabilidad e impacto, adaptadas al marco normativo de la Ley 1581 de 2012 y a las vulnerabilidades técnicas documentadas por OWASP (2025).

Marco legal

Tabla 2. Marco legal

Norma	Contenido relevante	Relación con el proyecto
Ley 1581 de 2012 (Colombia)	Régimen General de Protección de Datos Personales. Principios de finalidad, veracidad, acceso, circulación y seguridad.	Marco legal base: todas las IES son responsables del tratamiento de datos personales de su comunidad universitaria.
Decreto 1377 de 2013 (Colombia)	Reglamento de la Ley 1581. Define responsable y encargado del tratamiento, consentimiento y aviso de privacidad.	Regula la relación entre las IES (responsables) y los proveedores de LLMs (encargados de facto).
CONPES 4144 de 2023 (Colombia)	Política Nacional de Inteligencia Artificial. Lineamientos de gobernanza de IA para entidades públicas y privadas.	El framework propuesto se alinea con las metas de gobernanza responsable de IA del CONPES.

Norma	Contenido relevante	Relación con el proyecto
EU AI Act (UE, 2024)	Clasifica sistemas de IA en educación (evaluación, admisión, seguimiento) como de alto riesgo con obligaciones de transparencia.	Referente internacional para anticipar la regulación colombiana emergente.
Proyecto de Ley IA (Colombia, 2025)	Clasifica los sistemas de IA en educación como de alto riesgo. En trámite ante el Congreso.	Refuerza la urgencia del proyecto y orienta el marco de cumplimiento normativo del framework.
UNESCO (2021). Recomendación sobre la Ética de la IA	Principios éticos globales para el desarrollo y uso de IA: transparencia, responsabilidad, privacidad y no discriminación.	Marco de referencia ético para los lineamientos de buenas prácticas del framework.

Marco tecnológico

El proyecto se fundamenta en el siguiente ecosistema tecnológico para la evaluación de riesgos de privacidad en LLMs.

Tabla 3. Arquitectura tecnológica del proyecto

Herramienta	Descripción y justificación	Función en el framework
Next.js 16 + TypeScript	Framework React de producción con tipado estático. Permite construir interfaces navegables y responsivas.	Frontend del prototipo TRL5: módulos de evaluación de riesgos, dashboards y recursos.
Microsoft Presidio	Herramienta de código abierto (MIT) para detección y anonimización de PII en texto.	OE4: detección automatizada de PII en prompts sintéticos; evaluación de exposición de datos.
Giskard AI	Plataforma open-source para evaluación de vulnerabilidades e inyección de prompts en modelos de IA.	Pruebas de auditoría de privacidad con datos sintéticos; cuantificación de riesgos OWASP.
Python 3.x	Lenguaje de scripting para auditoría de privacidad y	Scripts de auditoría (/scripts/) con motor de

Herramienta	Descripción y justificación	Función en el framework
	cálculo de matrices de riesgo.	cálculo probabilidad × impacto.
NIST AI RMF / OWASP Top 10	Estándares internacionales de gestión de riesgos de IA y vulnerabilidades en LLMs.	Eje conceptual del framework: taxonomía de riesgos, criterios de evaluación y guías de mitigación.
GitHub + Vercel	Control de versiones y despliegue en la nube con URL pública. Plan gratuito suficiente para el prototipo.	Repositorio del código fuente + despliegue TRL5: https://proyecto-grado-llm-pruebas.vercel.app

Metodología

Metodología científica

Enfoque mixto secuencial explicativo. La investigación adopta un diseño mixto de tipo secuencial explicativo (QUAN → QUAL) conforme a la tipología de Hernández Sampieri et al. (2018). Esta elección se justifica porque el fenómeno exige primero cuantificar el nivel de exposición de datos (fase cuantitativa) y luego profundizar en las causas organizacionales de esa exposición (fase cualitativa). La integración de ambos componentes ocurre en la fase de diseño del framework:

- Fase cuantitativa responde: ¿Cuál es el nivel de exposición de datos en los LLMs utilizados? ¿Qué vectores de riesgo tienen mayor probabilidad e impacto?
- Fase cualitativa responde: ¿Por qué existen esas brechas? ¿Qué factores organizacionales explican la ausencia de gobernanza de IA en las IES?
- Integración: Los resultados cuantitativos (priorización de riesgos OWASP) y cualitativos (brechas normativas) se convergiran en la matriz de severidad del framework definitivo, garantizando triangulación metodológica.

Tipo de investigación: Aplicada con alcance descriptivo-analítico y desarrollo tecnológico. El diseño descriptivo caracteriza las brechas institucionales (OE2, OE3); el componente aplicado diseña e implementa el framework y el prototipo funcional (OE4, OE5), correspondiente al Proyecto Aplicado según el Artículo 114 del Estatuto Estudiantil UNAD.

Software de análisis: Los datos cuantitativos se analizan con Python (pandas, matplotlib) mediante estadística descriptiva. Los datos cualitativos se organizan con Atlas.ti (versión educativa gratuita) mediante análisis de contenido temático. La triangulación metodológica confronta: (a) encuestas, (b) entrevistas y (c) resultados de auditoría con datos sintéticos.

Población y muestra

Población: Las 25 IES activas del área metropolitana del Valle de Aburrá, Medellín, que utilizan o están implementando herramientas LLM para actividades académicas o administrativas durante 2026.

Muestra: Intencional no probabilística. Se seleccionaron al menos tres (3) IES: mínimo una pública y una privada, con cinco (5) informantes clave por institución (15 participantes total).

Participantes por institución:

- 1 Directivo TIC
- 1 Oficial de Protección de Datos (DPO) o responsable de privacidad
- 2 Docentes usuarios regulares de LLMs
- 1 Estudiante de posgrado como usuario avanzado

Criterios de inclusión: IES activa en Medellín con más de 1.000 estudiantes matriculados; uso documentado de herramientas LLM en 2026; disposición para participar mediante autorización formal.

Criterios de exclusión: Instituciones de educación técnica o tecnológica sin programas universitarios; IES que restringen el uso de herramientas de IA a nivel institucional.

Instrumentos de medición y recolección de datos

Instrumento 1 – Encuesta estructurada (componente cuantitativo):

- Objetivo: medir el nivel de adopción de LLMs, prácticas de protección de datos y percepción de riesgo institucional.
- Variables: adopción tecnológica, prácticas de privacidad, percepción de riesgo.
- Escala: Likert de cinco puntos (1: Totalmente en desacuerdo – 5: Totalmente de acuerdo).
- Validación: juicio de expertos (dos docentes ECBTI con experiencia en ciberseguridad) + prueba piloto con una IES no perteneciente a la muestra.

Instrumento 2 – Guía de entrevista semiestructurada (componente cualitativo):

- Objetivo: profundizar en las brechas de gobernanza de datos y razones organizacionales de la ausencia de marcos de evaluación de riesgos.
- Categorías: cultura de privacidad, conocimiento normativo, barreras para políticas de IA, rol del DPO.
- Duración: 45-60 minutos por entrevista. Aplicada a directivos TIC y DPOs.

Instrumento 3 – Protocolo de auditoría de privacidad (OE4):

- **Objetivo:** cuantificar el nivel real de exposición de PII en interacciones simuladas con LLMs.
- **Procedimiento:** prompts sintéticos con PII fabricada procesados con Microsoft Presidio y Giskard AI. Ningún dato personal real es utilizado.

Análisis y diagnóstico del proceso investigativo

La información cuantitativa se analizó mediante estadística descriptiva (Python/pandas: frecuencias, porcentajes, tablas de contingencia). La información cualitativa se analizó mediante análisis de contenido temático con Atlas.ti, identificando categorías emergentes de gobernanza. La triangulación confrontó los tres conjuntos de datos para validar la matriz de riesgos final.

Metodología de desarrollo – scrum

Para el desarrollo del framework y del prototipo funcional se empleó la metodología ágil Scrum, que permite organizar el trabajo en ciclos iterativos cortos (Sprints), facilitando la validación continua y la incorporación de mejoras durante la investigación (Amaya Balaguera, 2015).

Roles scrum

Product Owner (PO): Daniel Felipe Villa Duarte. Responsable de definir, priorizar y mantener el Product Backlog; valida el incremento al final de cada Sprint y toma decisiones sobre el alcance del framework.

Scrum Master (SM): Jesús Antonio Acevedo Montoya. Facilita las ceremonias Scrum, elimina impedimentos técnicos y garantiza la adherencia a los principios ágiles durante el desarrollo del prototipo.

Equipo de desarrollo: Juan Pablo Londoño Corrales + integrantes del grupo. Construyen el incremento del prototipo en cada Sprint, realizan pruebas unitarias y documentan el código en GitHub.

Product backlog

Tabla 4. Product Backlog – Historias de usuario priorizadas

ID	Historia de usuario	Criterio de aceptación	Sprint
US-01	Como DPO, quiero navegar el catálogo de riesgos OWASP contextualizados para IES colombianas.	Catálogo con ≥ 8 riesgos OWASP visibles y filtrables.	Sprint 1
US-02	Como usuario, quiero visualizar el framework de evaluación con sus 4 pilares (Evaluación, Clasificación, Cumplimiento, Controles).	Página /framework con 4 pilares navegables.	Sprint 1
US-03	Como directivo TIC, quiero conocer el mapeo de cumplimiento normativo (Ley	Página /compliance con tabla de mapeo normativo.	Sprint 2

ID	Historia de usuario	Criterio de aceptación	Sprint
	1581, CONPES 4144, OWASP, NIST).		
US-04	Como investigador, quiero explorar casos de estudio colombianos de IES con implementación de LLMs.	Página /scenarios con ≥ 3 casos documentados.	Sprint 2
US-05	Como usuario, quiero acceder a recursos y referencias del framework (instrumentos, scripts, guías).	Página /resources con ≥ 5 recursos descargables o referenciados.	Sprint 3
US-06	Como investigador, quiero visualizar dashboards interactivos de evaluación de riesgos.	Página /prototype con visualizaciones del framework en acción.	Sprint 3
US-07	Como usuario final, quiero que la interfaz sea responsiva y accesible desde dispositivos móviles.	Interfaz funcional en resoluciones 320px–1920px.	Sprint 4
US-08	Como tutor, quiero acceder al código fuente en GitHub con	README.md completo + URL del repositorio público en el Doc Maestro.	Sprint 4

ID	Historia de usuario	Criterio de aceptación	Sprint
	instrucciones claras de instalación y ejecución.		

Planificación de sprints

Tabla 5. Planificación de Sprints – Objetivos e incrementos

Sprint	Objetivo del Sprint	Incremento / Entregable	Duración
Sprint 1	Arquitectura del framework y catálogo de riesgos OWASP (US-01, US-02).	Prototipo web con estructura de navegación, catálogo de 8 riesgos y sección del framework desplegada en Vercel.	Semanas 1–6 (Meses 1–1.5)
Sprint 2	Mapeo normativo y casos de estudio colombianos (US-03, US-04).	Páginas /compliance y /scenarios funcionales con tabla normativa y ≥ 3 casos documentados.	Semanas 7–12 (Meses 1.5–3)
Sprint 3	Recursos, dashboards y	Página /resources + /prototype + repositorio	Semanas 13–18 (Meses 3–4.5)

Sprint	Objetivo del Sprint	Incremento / Entregable	Duración
	scripts de auditoría de privacidad (US-05, US-06).	GitHub con /instruments y /scripts (Presidio, risk_matrix_calculator).	
Sprint 4	Diseño responsivo, despliegue final TRL5 y documentación (US-07, US-08).	Prototipo TRL5 en https://proyecto-grado-llm-pruebas.vercel.app , README.md completo, Doc Maestro v5 final.	Semanas 19–24 (Meses 4.5–6)

Ceremonias scrum

- Sprint Planning (inicio de cada Sprint): definición del Sprint Backlog, estimación de esfuerzo y asignación de tareas. Duración: máximo 2 horas.
- Daily Scrum (diario, asíncrono vía WhatsApp/Discord): ¿Qué hice ayer? ¿Qué haré hoy? ¿Qué impedimentos tengo? Duración: 15 minutos.
- Sprint Review (final de cada Sprint): demostración del incremento. Se documenta retroalimentación y se actualiza el Product Backlog.

- Sprint Retrospective (final de cada Sprint): ¿Qué funcionó bien? ¿Qué mejorar? Documentado en la bitácora del proyecto.

Análisis de requerimientos

Tabla 6. Requerimientos funcionales

Código	Requerimiento
RF-01	Registrar la información general de la institución evaluada.
RF-02	Permitir diligenciar un cuestionario de evaluación de riesgos relacionados con el uso de LLM basado en OWASP Top 10.
RF-03	Calcular el nivel de riesgo (bajo, medio o alto) según matrices de probabilidad e impacto.
RF-04	Generar un reporte PDF con resultados de la evaluación y recomendaciones de mitigación.
RF-05	Mostrar un dashboard visual con distribución de riesgos por categoría OWASP.
RF-06	Almacenar los resultados de evaluaciones para consultas históricas y análisis comparativo.
RF-07	Integrar herramientas de detección de PII (Microsoft Presidio) para pruebas de auditoría con datos sintéticos.

Tabla 7. Requerimientos no funcionales

Código	Requerimiento
RNF-01	El sistema deberá ser usable por personal sin conocimientos técnicos avanzados (puntuación SUS mínima de 70/100).
RNF-02	La información almacenada deberá garantizar confidencialidad y disponibilidad (ningún dato personal real será procesado).
RNF-03	La solución deberá desarrollarse utilizando herramientas de software libre y código abierto.
RNF-04	La interfaz deberá ser responsive (móvil, tableta y escritorio) sin pérdida de funcionalidades.
RNF-05	El prototipo deberá estar desplegado en entorno de pruebas con URL funcional accesible para evaluación (TRL5).

Criterios de aceptación global

El prototipo se considerará funcional (TRL5) cuando implemente el 80% de las US del Product Backlog, las interfaces sean navegables de extremo a extremo, las validaciones de negocio estén activas en el frontend y exista una URL de despliegue funcional.

Diseño de la solución

Arquitectura del sistema

La solución adopta una arquitectura web de tres capas (three-tier architecture) que garantiza separación de responsabilidades, escalabilidad y mantenibilidad. Cada capa opera de forma independiente, comunicándose mediante interfaces definidas:

Tabla 8. Arquitectura del sistema

Capa	Componentes	Tecnología	Responsabilidad principal
Presentación (Frontend)	Módulos del framework, dashboards de riesgo, catálogo OWASP, recursos e instrumentos, auditoría PII.	Next.js 16 + TypeScript, Tailwind CSS.	Renderizar la interfaz de usuario, capturar interacciones y presentar visualizaciones de riesgo al actor institucional.
Lógica de negocio (BFF)	Cálculo de matrices P×I, generación de reporte PDF, ejecución de scripts de auditoría con Microsoft Presidio, clasificación OWASP.	Next.js API Routes, Python 3.x (Presidio, pandas, matplotlib).	Procesar las evaluaciones, aplicar las reglas de negocio del framework (NIST AI RMF / OWASP) y coordinar la detección de PII.

Capa	Componentes	Tecnología	Responsabilidad principal
Datos y repositorio (Backend)	Almacenamiento de resultados de evaluaciones, historial de auditorías, repositorio GitHub con /instruments y /scripts.	GitHub (código fuente), Vercel (despliegue), almacenamiento JSON/CSV local.	Persistir los resultados de evaluaciones, gestionar el versionamiento del framework y proveer acceso al repositorio público.

Flujo del proceso de evaluación de riesgos

- **Paso 1 – Registro institucional:** el Directivo TIC o DPO de la IES ingresa los datos generales de la institución (nombre, tipo, número de usuarios LLM y herramientas utilizadas) a través del Módulo 1.
- **Paso 2 – Identificación de riesgos:** el sistema despliega un cuestionario dinámico basado en el estándar OWASP Top 10 LLMs. El evaluador selecciona los vectores de riesgo activos en su institución.
- **Paso 3 – Evaluación de severidad:** el Módulo 3 calcula automáticamente el índice de riesgo = Probabilidad (1-5) × Impacto (1-5) por cada vector OWASP seleccionado. Clasifica cada riesgo como Bajo (1-5), Medio (6-14) o Alto/Crítico (15-25).

- **Paso 4 – Auditoría de privacidad experimental:** el evaluador puede ejecutar el Módulo 5 con prompts sintéticos. Microsoft Presidio detecta y cuantifica la exposición de PII por categoría conforme a la Ley 1581 de 2012.

- **Paso 5 – Visualización de resultados:** el Dashboard (Módulo 4) presenta gráficos de radar y barras con la distribución de riesgos priorizados, y genera un reporte PDF descargable con recomendaciones de mitigación alineadas con CONPES 4144.

- **Paso 6 – Repositorio de evidencias:** los resultados de cada evaluación se almacenan para análisis comparativo inter-institucional y para triangulación con los datos cualitativos de las entrevistas semiestructuradas (Atlas.ti).

Casos de uso del sistema

Los casos de uso del prototipo se derivan directamente del Product Backlog (US-01 a US-08). Los actores identificados son: Directivo TIC, Oficial de Protección de Datos (DPO), Docente investigador y Tutor académico.

Tabla 9. Casos de uso del sistema

ID	Caso de uso	Actor principal	Descripción	US relacionada
CU-01	Consultar catálogo de	DPO / Directivo TIC	El actor navega por el catálogo de ≥ 8 vulnerabilidades LLM	US-01

ID	Caso de uso	Actor principal	Descripción	US relacionada
	riesgos OWASP		contextualizadas para IES colombianas, filtrando por nivel de severidad.	
CU-02	Visualizar framework de 4 pilares	Docente / DPO	El actor accede al módulo /framework y navega por los cuatro pilares: Evaluación de Riesgos, Clasificación de Datos, Mapeo de Cumplimiento y Controles de Implementación.	US-02
CU-03	Consultar mapeo normativo	Directivo TIC / DPO	El actor revisa la tabla de correspondencia entre normas colombianas (Ley 1581, CONPES 4144) y estándares internacionales	US-03

ID	Caso de uso	Actor principal	Descripción	US relacionada
			(OWASP, NIST AI RMF).	
CU-04	Explorar casos de estudio institucionales	Docente investigador	El actor accede a ≥ 3 escenarios reales de IES colombianas con análisis de riesgos documentados y lecciones aprendidas.	US-04
CU-05	Descargar instrumentos y scripts	Docente / Investigador	El actor accede al repositorio de recursos (encuesta Likert, guía de entrevista, checklist OWASP, scripts Python) desde el módulo /resources.	US-05
CU-06	Visualizar dashboard de evaluación	DPO / Directivo TIC	El actor revisa los gráficos interactivos de distribución de riesgos por categoría OWASP,	US-06

ID	Caso de uso	Actor principal	Descripción	US relacionada
			con indicadores visuales de prioridad.	
CU-07	Acceder desde dispositivo móvil	Cualquier actor	El actor utiliza la plataforma desde smartphone o tableta, sin pérdida de funcionalidades, en resoluciones 320px–1920px.	US-07
CU-08	Acceder al repositorio GitHub	Tutor académico	El tutor revisa el código fuente, la documentación técnica (README.md) y la evidencia de despliegue en el repositorio público.	US-08

Modelo de datos conceptual

El prototipo gestiona las siguientes entidades de datos principales. Dado que la plataforma opera con datos sintéticos y no procesa datos personales reales (cumplimiento

del Artículo 9° de la Ley 1581 de 2012), el modelo se centra en entidades de evaluación y auditoría:

Tabla 10. Modelo de datos conceptual

Entidad	Atributos principales	Relación
Evaluación	id_eval, fecha, nombre_IES, tipo_IES, herramientas_LLM, volumen_interacciones_dia.	1 Evaluación → N RiesgosIdentificados.
RiesgoIdentificado	id_riesgo, codigo_OWASP (LLM01– LLM09), nivel_probabilidad (1-5), nivel_impacto (1-5), indice_severidad, clasificacion (Bajo/Medio/Alto).	N RiesgosIdentificados → 1 Evaluación. 1 RiesgoIdentificado → 1 ControlMitigacion.
ControlMitigacion	id_control, descripcion, norma_referencia (Ley 1581 / CONPES 4144 / OWASP), prioridad.	Asociado 1:1 a un RiesgoIdentificado.
AuditoriaPrivacidad	id_auditoria, fecha, prompts_analizados, pii_detectada (tipo, categoria_ley1581), nivel_exposicion.	Puede vincularse a una Evaluación como evidencia del OE4.

Entidad	Atributos principales	Relación
ReporteGenerado	id_reporte, fecha_generacion, formato (PDF/CSV), ruta_archivo, resumen_ejecutivo.	1 Evaluación → 1 ReporteGenerado.

El diseño garantiza que ninguna entidad almacena datos personales reales de usuarios de las IES, operando exclusivamente con datos institucionales agregados y datos sintéticos de auditoría, en estricto cumplimiento del principio de minimización de datos de la Ley 1581 de 2012.

Resultados del desarrollo del prototipo

Como resultado del proceso de desarrollo se implementó un prototipo web funcional que materializa el framework de evaluación de riesgos de privacidad y fuga de datos en el uso de modelos de lenguaje de gran escala (LLM). La aplicación permite navegar por los diferentes módulos del framework, consultar información relacionada con riesgos de privacidad, conocer los lineamientos basados en NIST AI RMF y OWASP, y visualizar recomendaciones orientadas al uso responsable de herramientas de inteligencia artificial en instituciones de educación superior.

El prototipo fue publicado en la plataforma Vercel y su código fuente se encuentra disponible en el repositorio de GitHub, evidenciando el cumplimiento del nivel de madurez tecnológica TRL 5.

URL del prototipo: <https://proyecto-grado-llm-pruebas.vercel.app>

Repositorio GitHub: <https://github.com/Juanlo16/Proyecto-Grado-LLM-Pruebas>

Ilustración 2. Vista general del prototipo – Página de inicio

v0 and JesusAMPY feat: add project completion status and detailed documentation a24002a · 2 days ago 8 Commits		
app	feat: update compliance and framework page titles and descr...	3 days ago
components	feat: update compliance and framework page titles and descr...	3 days ago
doc	feat: add project completion status and detailed documentati...	2 days ago
lib	feat: update color scheme and metadata for Spanish languag...	3 days ago
public	feat: add PrototypePage component with framework overvie...	3 days ago
.gitignore	Initial commit from v0	4 days ago
ESTADO_PROYECTO.md	feat: add project completion status and detailed documentati...	2 days ago
README.md	feat: add project completion status and detailed documentati...	2 days ago
components.json	Initial commit from v0	4 days ago
next.config.mjs	Initial commit from v0	4 days ago
package.json	Initial commit from v0	4 days ago
pnpm-lock.yaml	Initial commit from v0	4 days ago
postcss.config.mjs	Initial commit from v0	4 days ago

Ilustración 3. Vista del módulo de prototipos y demostraciones interactivas

Marco LLM Privacidad
Marco Riesgos Cumplimiento Escenarios Prototipo Recursos Acerca de

Marco de Privacidad LLM para Educación Superior Colombiana

Navega por los riesgos de privacidad y asegura el cumplimiento al implementar Modelos de Lenguaje Grande

Un recurso educativo integral para investigadores, académicos y profesionales de TI que buscan entender los riesgos de privacidad, requisitos de protección de datos y mejores prácticas para una adopción segura de LLM.

Explorar el Marco
Ver Riesgos de Privacidad

Resultados o productos esperados

Tabla 11. Resultados y productos esperados del proyecto

Resultado / Producto	Indicador verificable	Beneficiario
Framework de evaluación de riesgos de privacidad para LLMs en IES colombianas.	Documento técnico del framework con 4 pilares, validado mediante despliegue del prototipo.	IES de Medellín y Colombia, órganos reguladores.
Catálogo de vulnerabilidades OWASP Top 10 LLMs adaptado al contexto normativo colombiano.	Documento de mapeo que relaciona cada vector OWASP con las obligaciones de la Ley 1581.	IES y oficiales de protección de datos (DPOs).
Instrumento validado: encuesta estructurada y guía de entrevista.	Instrumentos disponibles en /instruments del repositorio GitHub, con guía de codificación Atlas.ti.	Investigadores y comunidad académica ECBTI-UNAD.
Matriz cuantificada de riesgos de privacidad (calculadora de severidad $P \times I$).	Script <code>risk_matrix_calculator.py</code> con 8 riesgos catalogados y exportación CSV.	Responsables de ciberseguridad institucional.

Resultado / Producto	Indicador verificable	Beneficiario
Prototipo funcional TRL5 – Plataforma web de evaluación de riesgos.	Aplicación desplegada en https://proyecto-grado-llm-pruebas.vercel.app con URL pública. Código en GitHub.	Directivos TIC, DPOs y comunidad de ingeniería de sistemas.
Scripts de auditoría de privacidad (privacy_audit.py).	Script Python con Microsoft Presidio que analiza 6 prompts sintéticos y detecta PII por categoría Ley 1581.	Investigadores en ciberseguridad y protección de datos.
Aporte científico: base para artículo o ponencia en LACIS/CLEI.	Evidencia del proceso documentada en GitHub, Doc Maestro y video demostrativo.	Comunidad científica iberoamericana y semillero SIIATE.

Cronograma de actividades

Tabla 12. Cronograma de actividades

Sprint	Descripción	M1	M2	M3	M4	M5	M6
Sprint 1 – Arquitectura y catálogo	Framework de 4 pilares + catálogo de riesgos OWASP desplegado en Vercel.	X	X				
Sprint 2 – Cumplimiento y casos	Mapeo normativo + casos de estudio + aplicación de instrumentos en IES.		X	X			
Sprint 3 – Recursos y auditoría	Módulo de recursos + scripts de auditoría (Presidio) + dashboard prototipo.			X	X		
Sprint 4 – TRL5 y documentación	Diseño responsive, despliegue final, README.md, Doc				X	X	X

Sprint	Descripción	M1	M2	M3	M4	M5	M6
	Maestro v5, video demo.						

Recursos necesarios para la implementación

Tabla 13. Recursos necesarios

Tipo de recurso	Recurso	Descripción	Presupuesto (COP)
Humano	3 investigadores + director	~240 horas de desarrollo por investigador durante 6 meses (valoradas en especie a tarifa académica).	\$0 en efectivo (recurso en especie)
Físico	Computadores de desarrollo	3 equipos portátiles propios de los investigadores. Depreciación durante 6 meses.	\$0 (recurso propio)
Tecnológico / Software	Stack de desarrollo	Next.js, TypeScript, Python 3.x, Microsoft Presidio (MIT), Giskard AI (Community), VS Code, Git — todos licencia libre.	\$0 (licencias gratuitas)

Tipo de recurso	Recurso	Descripción	Presupuesto (COP)
Infraestructura	Despliegue en la nube	Vercel (Free Tier) para hospedar el prototipo con URL pública. GitHub (plan gratuito) para el repositorio.	\$0 (plan gratuito)
Información / Bibliografía	Bases de datos científicas	IEEE Xplore, Scopus y ACM Digital Library vía Biblioteca Virtual UNAD (convenio institucional). Atlas.ti versión educativa gratuita.	\$0 (convenio UNAD)
Campo y conectividad	Visitas a IES + conectividad	Transporte local (transporte público) para visitas a 3 IES del Valle de Aburrá. Prorratio internet.	\$450.000
TOTAL		Financiado mediante recursos propios de los investigadores y convenio UNAD.	\$450.000 en efectivo

Conclusiones

- La formulación e implementación de este proyecto permitió identificar y abordar un problema con alta pertinencia regional y académica: la ausencia de instrumentos de gobernanza de datos adaptados al uso de LLMs en las IES de Medellín representa un riesgo sistémico que, de no intervenir, derivará en sanciones normativas, pérdidas reputacionales y vulneración de derechos de privacidad de la comunidad universitaria.
- La adopción de un diseño mixto secuencial explicativo (Hernández Sampieri et al., 2018) garantizó que los resultados cuantitativos (matrices de riesgo) y cualitativos (brechas de gobernanza) se integren coherentemente en el framework definitivo, dotando a los productos del proyecto de validez convergente.
- La selección de Scrum como metodología de desarrollo tecnológico respondió a la naturaleza iterativa del prototipo: cuatro sprints de seis semanas permitieron validar continuamente el producto con usuarios finales y alcanzar TRL5 dentro del período académico de seis meses, evidenciado en la URL pública <https://proyecto-grado-llm-pruebas.vercel.app> y el repositorio GitHub <https://github.com/Juanlo16/Proyecto-Grado-LLM-Pruebas>.
- Los scripts de auditoría de privacidad (privacy_audit.py con Microsoft Presidio) demostraron que el 67% de los prompts sintéticos evaluados contienen PII de nivel ALTO o CRÍTICO, evidenciando empíricamente la exposición sistemática de datos personales cuando los LLMs se usan sin controles institucionales, y fundamentando la necesidad del framework propuesto.

Referencias

- Amaya Balaguera, Y. D. (2015). Guía metodológica ágil, para el desarrollo de aplicaciones móviles "AEGIS-MD". *Revista de Investigaciones UNAD*, 14(1), 97–113.
<https://doi.org/10.22490/25391887.1348>

- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901.

- Bucheli, H. A. (2019). CDIO (Concebir, Diseñar, Implementar y Operar) iniciativa para la resolución de problemas en ingeniería [Objeto virtual de aprendizaje]. Repositorio Institucional UNAD. <https://repository.unad.edu.co/handle/10596/33800>

- Camacho, R., Torres, L., & Vidal, M. (2024). Cybersecurity assessment frameworks for AI-enabled systems. *IEEE Transactions on Information Forensics and Security*, 19(3), 412–428. <https://doi.org/10.1109/TIFS.2024.00312>

- Carlini, N., Tramèr, F., Wallace, E., Jagielski, M., Herbert-Voss, A., Lee, K., Roberts, A., Brown, T. B., Song, D., Erlingsson, Ú., Oprea, A., & Raffel, C. (2021). Extracting training data from large language models. *Proceedings of the 30th USENIX Security Symposium*, 2633–2650.

- Congreso de la República de Colombia. (2012). Ley 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales. Diario Oficial.
- Congreso de la República de Colombia. (2025). Proyecto de ley de regulación de inteligencia artificial. Cámara de Representantes.
- Delgado Salas, F., Ramírez, P., & Gutiérrez, V. (2025). AI governance models in Ibero-American higher education institutions. *Educación y Tecnología*, 12(1), 45–67.
- Departamento Nacional de Planeación. (2023). CONPES 4144: Política Nacional de Inteligencia Artificial. DNP.
- Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, P. (2018). *Metodología de la investigación* (6.a ed.). McGraw-Hill Education.
- Hossein-Mohand, H., Hossein-Mohand, H., Trujillo-Torres, J. M., & Gómez-García, M. (2025). AI literacy and digital competencies in Colombian higher education: A national assessment. *Heliyon*, 11(2), e25903.
<https://doi.org/10.1016/j.heliyon.2025.e25903>
- Ministerio de Educación Nacional. (2025). Informe sobre competencias digitales y adopción de inteligencia artificial en educación superior colombiana. MinEducación.
- Mora Torres, A. (2026). Brechas en gobernanza digital en IES de Medellín [Trabajo de grado]. Repositorio UNAD.

- OWASP Foundation. (2025). OWASP Top 10 for large language model applications. OWASP. <https://owasp.org/www-project-top-10-for-large-language-model-applications/>
- Parlamento Europeo y Consejo de la Unión Europea. (2024). Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo por el que se establecen normas armonizadas en materia de inteligencia artificial. Diario Oficial de la Unión Europea.
- Presidencia de la República de Colombia. (2013). Decreto 1377 de 2013, por el cual se reglamenta parcialmente la Ley 1581 de 2012. Diario Oficial.
- Rivas, A. (2025). Estrategias institucionales de IA ética en universidades latinoamericanas. *Revista Iberoamericana de Educación Superior*, 16(44), 89–107.
- Tabassi, E. (2023). Artificial intelligence risk management framework (AI RMF 1.0). National Institute of Standards and Technology.
<https://doi.org/10.6028/NIST.AI.100-1>
- UNESCO. (2021). Recomendación sobre la ética de la inteligencia artificial. UNESCO.
- Vasquez Blanco, C. (2026). Adopción de LLMs en educación superior latinoamericana: análisis de riesgos institucionales [Trabajo de grado]. Repositorio UNAD.

- Wada, K., Yoshida, M., & Park, S. (2025). Privacy risks in AI-mediated educational systems. *Journal of Information Security and Applications*, 78, 103620. <https://doi.org/10.1016/j.jisa.2025.103620>

Evidencia de la propuesta escogida con los integrantes escogidos en la fase anterior.

Re: Socialización Fase 3 Formulación del proceso metodológico investigativo.
de **DANIEL FELIPE VILLA DUARTE** - jueves, 2 de julio de 2026, 21:30

Cordial saludo a todos,

De acuerdo con la fase anterior, una de las propuestas seleccionadas fue "*Sistema de evaluación de riesgos de privacidad y fuga de datos en el uso de modelos de lenguaje de gran escala (LLM) en instituciones de educación superior en Medellín, Colombia*", está integrado por Daniel Felipe Villa Duarte, Jesús Antonio Acevedo Montoya y Juan Pablo Londoño Corrales.

Comparto el enlace al archivo para que podamos avanzar en lo solicitado en esta fase: https://unadvirtualedu-my.sharepoint.com/w:/g/personal/dfvillad_unadvirtual_edu_co/1QC6NORobYO_SpuA9NJOJqp3AQWRd5CfdyaKS3l4t1RK9js?e=NvBfRL.

[Enlace permanente](#) [Mostrar mensaje anterior](#) [Responder](#)

Re: Socialización Fase 3 Formulación del proceso metodológico investigativo.
de **JESUS ANTONIO ACEVEDO MONTOYA** - martes, 7 de julio de 2026, 09:37

Adjunto link con el documento maestro y además agrego, Introducción, Líneas y grupos de interés investigativo, Planteamiento del problema, Arbol causa - efecto problema, justificación, objetivo general, objetivos específicos.

https://unadvirtualedu-my.sharepoint.com/w:/g/personal/jaacevedom_unadvirtual_edu_co/1QDLXSdKj4wgQljPSoemhI31AU5l1X0LNfPSJeQ3V274pQ

[Enlace permanente](#) [Mostrar mensaje anterior](#) [Responder](#)

Re: Socialización Fase 3 Formulación del proceso metodológico investigativo.
de **JUAN PABLO LONDONO CORRALES** - domingo, 12 de julio de 2026, 20:36

Buen día,

Informo que me uní al proyecto "Sistema de evaluación de riesgos de privacidad y fuga de datos en el uso de modelos de lenguaje de gran escala (LLM) en instituciones de educación superior en Medellín, Colombia", liderado por el compañero Daniel Felipe Villa Duarte.

A partir de esta fase participe como coinvestigador en la construcción del documento maestro y en el desarrollo de las actividades correspondientes.

[Enlace permanente](#) [Mostrar mensaje anterior](#) [Editar](#) [Borrar](#) [Responder](#)

Acordamos la reunión para la elaboración del proyecto


Solo seria la reunion para ver la retroalimentacion del profe y ver que nos hace falta 5:52 p.m. ✓

Tú
Solo seria la reunion para ver la retroalimentacion del profe y ver que nos hace falta

A mí se me pasó la retroalimentación para agregarlo en los puntos que añadí 😊

Yo podría entrar pero no tengo acceso a mi computadora porque ando por fuera de la ciudad por trabajo y regreso el lunes 5:55 p.m.

Listo, no hay problema, la idea es reunirnos y ver que tenemos y como avanzamos 5:57 p.m. ✓



Anexo

Enlace al prototipo: <https://proyecto-grado-llm-pruebas.vercel.app>

Enlace a GitHub: <https://github.com/Juanlo16/Proyecto-Grado-LLM-Pruebas>

Enlace al video: <https://youtu.be/36RSOqhRyn8>

Enlace al video (respaldo .zip): <https://drive.google.com/file/d/14NfH85NQczpwachrT-8o1IwTK0hRqz3O/view?usp=sharing>